🐧 🐧 Tarea 1 --- IELE756 🐧 🐧

Equipo Pinguino conformado por : Hellen Quiñones, Gustavo Sánchez

Comunas Asignadas: Alhue, La Pintana, Huechuraba, El Monte, María Pinto

Date: 26-03-26

Link al repositorio de GitHub: https://github.com/hellenelizabethqm-netizen/iele756-region-XXXX

Cargamos las Bibliotecas

In [1]:
```
import pandas as pd
import pyarrow.parquet as pq
import fastparquet
import numpy as np
import matplotlib.pyplot as plt
import geopandas as gpd
```

Lectura de los archivos a ocupar

especificando las columnas(variables) que se utilizaran

- personas_censo2024:

  `id_vivienda` , `id_hogar` , `id_persona` , `sexo` , `edad` , `p27_nacionalidad` , `p27_nacionalidad_esp` , `p27_nacionalidad_rec` , `p24_lug_resid5` , `p24_lug_resid5_esp` , `p25_lug_nacimiento` , `p25_lug_nacimiento_rec` , `p26_llegada_periodo` , `escolaridad` , `cine11` , `sit_fuerza_trabajo` , `cod_ciuo` , `cod_caenes` , `p45_medio_transporte`

- viviendas_censo2024:

  `id_vivienda` , `region` , `comuna` , `p4a_mat_paredes` , `p4b_mat_techo` , `p4c_mat_piso`

- hogares_censo2024:

  `id_vivienda` , `id_hogar` , `p12_tenencia_viv` , `tipologia_hogar`

In [2]:
```
personas = pd.read_parquet("personas_censo2024.parquet", engine="fastparquet", c
"p27_nacionalidad","p27_nacionalidad_esp", "p27_nacionalidad_rec", "p24_lug_resi
"cod_ciuo", "cod_caenes", "p45_medio_transporte"])

personas
```

Out[2]:

	id_vivienda	id_hogar	id_persona	sexo	edad	p27_nacionalidad	p27_nacion
0	1	1	1	2	80	1	
1	1	1	2	1	52	1	
2	1	1	3	2	45	1	
3	1	1	4	2	8	1	
4	2	1	1	1	69	1	
...	...	...	...	...	...	...	
18480427	7664466	1	2	1	31	1	
18480428	7664466	1	3	1	24	1	
18480429	7664466	1	4	2	34	1	
18480430	7664466	1	5	1	2	1	
18480431	7664466	1	6	2	0	1	

18480432 rows × 19 columns

In [3]:

```
viviendas = pd.read_parquet("viviendas_censo2024.parquet", engine="fastparquet",
       'p4b_mat_techo', 'p4c_mat_piso'])

viviendas
```

Out[3]:

	id_vivienda	region	comuna	p4a_mat_paredes	p4b_mat_techo	p4c_mat_piso
0	1	5	5802	5.0	1.0	2.0
1	2	4	4303	2.0	3.0	3.0
2	3	11	11202	2.0	3.0	1.0
3	4	1	1101	1.0	2.0	1.0
4	5	8	8301	2.0	3.0	1.0
...	...	...	...	...	...	...
7664461	7664462	3	3101	2.0	4.0	1.0
7664462	7664463	14	14202	3.0	3.0	1.0
7664463	7664464	9	9105	3.0	3.0	1.0
7664464	7664465	5	5101	1.0	3.0	1.0
7664465	7664466	13	13122	2.0	1.0	1.0

7664466 rows × 6 columns

In [4]:

```
hogares = pd.read_parquet("hogares_censo2024.parquet", engine="fastparquet", col

hogares
```

Out[4]:

	id_vivienda	id_hogar	p12_tenencia_viv	tipologia_hogar
0	1	1	4.0	5.0
1	2	1	9.0	7.0
2	3	1	3.0	4.0
3	4	1	3.0	4.0
4	5	1	1.0	1.0
...	...	...	...	...
6622592	7664462	1	2.0	4.0
6622593	7664463	1	4.0	1.0
6622594	7664464	1	1.0	1.0
6622595	7664465	1	1.0	2.0
6622596	7664466	1	1.0	5.0

6622597 rows × 4 columns

In [5]:
```
OUR_COMUNAS = [13107, 13112, 13502, 13504, 13602]
```

In [6]:
```
viv = viviendas[viviendas["comuna"].isin(OUR_COMUNAS)]
hog = hogares[hogares["id_vivienda"].isin(viv["id_vivienda"])]
per = personas[personas["id_vivienda"].isin(viv["id_vivienda"])]
```

- Lo primero a hacer fue definir las comunas de interés para el análisis: **Alhué, El Monte, Huechuraba, La Pintana y María Pinto**, identificadas mediante sus respectivos códigos territoriales. A partir de esa selección, se filtraron las tres tablas principales del censo (`vivienda` , `hogar` y `persona`) para conservar únicamente los registros asociados a estas comunas.

In [7]:
```
rows_02 = pd.DataFrame({"tabla": ["vivienda", "hogar", "persona"],"n_filas": [le

rows_02
```

Out[7]:

	tabla	n_filas
0	vivienda	107157
1	hogar	106575
2	persona	337846

- Como resultado del filtrado, la tabla de **vivienda** quedó con **107.157 filas**, la tabla de **hogar** con **106.575 filas** y la tabla de **persona** con **337.846 filas**. Mostrando que el subconjunto de datos aun es grande, pero restringido exclusivamente al territorio(comunas) que tenemos que analizar

In [8]:
```
df = per.merge(hog, on=["id_vivienda", "id_hogar"], how="left") \
        .merge(viv, on="id_vivienda", how="left")
assert len(df) == len(per), "Row count mismatch after join!"

print(df.shape)

print("[-----------------------------------------------------------------------------

df.info()
```

```
(337846, 26)
[-----------------------------------------------------------------------------]
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 337846 entries, 0 to 337845
Data columns (total 26 columns):
 #   Column                  Non-Null Count   Dtype
---  ------                  --------------   -----
 0   id_vivienda             337846 non-null  int32
 1   id_hogar                337846 non-null  int32
 2   id_persona              337846 non-null  int32
 3   sexo                    337846 non-null  int32
 4   edad                    337846 non-null  int32
 5   p27_nacionalidad        337846 non-null  int32
 6   p27_nacionalidad_esp    337846 non-null  int32
 7   p27_nacionalidad_rec    337846 non-null  int32
 8   p24_lug_resid5          337846 non-null  int32
 9   p24_lug_resid5_esp      320341 non-null  float64
 10  p25_lug_nacimiento      337846 non-null  int32
 11  p25_lug_nacimiento_rec  337846 non-null  int32
 12  p26_llegada_periodo     20079 non-null   float64
 13  escolaridad             337846 non-null  int32
 14  cine11                  337846 non-null  int32
 15  sit_fuerza_trabajo      270608 non-null  float64
 16  cod_ciuo                144086 non-null  float64
 17  cod_caenes              144086 non-null  object
 18  p45_medio_transporte    124444 non-null  float64
 19  p12_tenencia_viv        336547 non-null  float64
 20  tipologia_hogar         336547 non-null  float64
 21  region                  337846 non-null  int32
 22  comuna                  337846 non-null  int32
 23  p4a_mat_paredes         336547 non-null  float64
 24  p4b_mat_techo           336547 non-null  float64
 25  p4c_mat_piso            336547 non-null  float64
dtypes: float64(10), int32(15), object(1)
memory usage: 47.7+ MB
```

- Posteriormente, las tablas filtradas se integraron en una sola con (`merge`) entre personas, hogares y viviendas. Además, se verificó que la cantidad de filas del dataframe final coincidiera con la tabla de personas.

In [9]:
```
dic_comunas = pd.read_excel("diccionario_variables_censo2024.xlsx",sheet_name="c

dic_comunas = dic_comunas[dic_comunas["División Política Administrativa"] == "Co

dic_comunas = dic_comunas[["Código territorial", "Territorio"]].copy()

dic_comunas = dic_comunas.rename(columns={"Código territorial": "comuna","Territ
```

```
df = df.merge(dic_comunas, on="comuna", how="left")

df[["comuna", "nombre_comuna"]].drop_duplicates().sort_values("comuna")
```

Out[9]:

	comuna	nombre_comuna
0	13107	Huechuraba
6	13112	La Pintana
69	13502	Alhué
194	13504	María Pinto
4	13602	El Monte

En esta parte agregamos el nombre de cada comuna al dataframe principal usando el diccionario de variables territoriales. Para eso, cargamos la hoja `codigos_territoriales`, filtramos solo las filas que correspondían a comunas y dejamos únicamente el código territorial junto con el nombre de este.

Después de renombrar esas columnas como `comuna` y `nombre_comuna`, hicimos un `merge` con el dataframe. Esto para que en los próximos gráficos se pueda ver el nombre de las comunas y no solo el código.

1.1 Age Pyramid by Sex

In [10]:

```
pyr = df[(df["edad"] != -99) & (df["p25_lug_nacimiento_rec"] != -99)].copy()

bins = list(range(0, 81, 5)) + [200]
labels = [f"{i}-{i+4}" for i in range(0, 80, 5)] + ["80+"]

pyr["age_group"] = pd.cut(pyr["edad"],bins=bins,labels=labels,right=False)

male_chile = (pyr[(pyr["sexo"] == 1) & (pyr["p25_lug_nacimiento_rec"] == 1)].gro

female_chile = (pyr[(pyr["sexo"] == 2) & (pyr["p25_lug_nacimiento_rec"] == 1)].g

male_foreign = (pyr[(pyr["sexo"] == 1) & (pyr["p25_lug_nacimiento_rec"] == 2)].g

female_foreign = (pyr[(pyr["sexo"] == 2) & (pyr["p25_lug_nacimiento_rec"] == 2)]
```

```
C:\Users\gusta\AppData\Local\Temp\ipykernel_71176\2261945352.py:8: FutureWarning:
The default of observed=False is deprecated and will be changed to True in a futu
re version of pandas. Pass observed=False to retain current behavior or observed=
True to adopt the future default and silence this warning.
  male_chile = (pyr[(pyr["sexo"] == 1) & (pyr["p25_lug_nacimiento_rec"] == 1)].gr
oupby("age_group").size().reindex(labels, fill_value=0))
C:\Users\gusta\AppData\Local\Temp\ipykernel_71176\2261945352.py:10: FutureWarnin
g: The default of observed=False is deprecated and will be changed to True in a f
uture version of pandas. Pass observed=False to retain current behavior or observ
ed=True to adopt the future default and silence this warning.
  female_chile = (pyr[(pyr["sexo"] == 2) & (pyr["p25_lug_nacimiento_rec"] == 1)].
groupby("age_group").size().reindex(labels, fill_value=0))
C:\Users\gusta\AppData\Local\Temp\ipykernel_71176\2261945352.py:12: FutureWarnin
g: The default of observed=False is deprecated and will be changed to True in a f
uture version of pandas. Pass observed=False to retain current behavior or observ
ed=True to adopt the future default and silence this warning.
  male_foreign = (pyr[(pyr["sexo"] == 1) & (pyr["p25_lug_nacimiento_rec"] == 2)].
groupby("age_group").size().reindex(labels, fill_value=0))
C:\Users\gusta\AppData\Local\Temp\ipykernel_71176\2261945352.py:14: FutureWarnin
g: The default of observed=False is deprecated and will be changed to True in a f
uture version of pandas. Pass observed=False to retain current behavior or observ
ed=True to adopt the future default and silence this warning.
  female_foreign = (pyr[(pyr["sexo"] == 2) & (pyr["p25_lug_nacimiento_rec"] ==
2)].groupby("age_group").size().reindex(labels, fill_value=0))
```

Aquí parte la base para la pirámide poblacional usando únicamente registros con edad "válida" y con información disponible sobre el lugar de nacimiento, para detectectar aquellos que efectivamente son extranjeros y aquellos que son chilenos. Luego, agrupamos la variable `edad` en tramos de 5 años, desde **0–4** hasta **80+**.

Después, se calcularon las frecuencias de hombres y mujeres, distinguiendo además entre población **chilena** y **extranjera**. Obteniendo cuatro series: hombres `chilenos`, `mujeres chilenas`, `hombres extranjeros` y `mujeres extranjeras`, las que luego se usan para construir la gráfica de pirámide poblacional.

In [11]:
```
fig, axes = plt.subplots(1, 2, figsize=(14, 8), sharey=True)

#Chilenos
ax = axes[0]
ax.barh(labels, -male_chile, label="Male", color="steelblue")
ax.barh(labels, female_chile, label="Female", color="lightcoral")
ax.axvline(0, color="black")
ax.set_title("Chilean-born")
ax.set_xlabel("Population")

#Extranjeros
ax = axes[1]
ax.barh(labels, -male_foreign, label="Male", color="steelblue")
ax.barh(labels, female_foreign, label="Female", color="lightcoral")
ax.axvline(0, color="black")
ax.set_title("Foreign-born")
ax.set_xlabel("Population")

max_x = max(
    male_chile.max(), female_chile.max(),
    male_foreign.max(), female_foreign.max())
for ax in axes:
```

```
    ax.set_xlim(-max_x * 1.05, max_x * 1.05)

#Eje X positivos en ambos
for ax in axes:
    xticks = ax.get_xticks()
    ax.set_xticklabels([f"{abs(int(x)):,}" for x in xticks])

axes[0].set_ylabel("Age group")
plt.tight_layout()

plt.show()
```

```
C:\Users\gusta\AppData\Local\Temp\ipykernel_71176\2159508241.py:28: UserWarning:
set_ticklabels() should only be used with a fixed number of ticks, i.e. after set
_ticks() or using a FixedLocator.
  ax.set_xticklabels([f"{abs(int(x)):,}" for x in xticks])
C:\Users\gusta\AppData\Local\Temp\ipykernel_71176\2159508241.py:28: UserWarning:
set_ticklabels() should only be used with a fixed number of ticks, i.e. after set
_ticks() or using a FixedLocator.
  ax.set_xticklabels([f"{abs(int(x)):,}" for x in xticks])
```

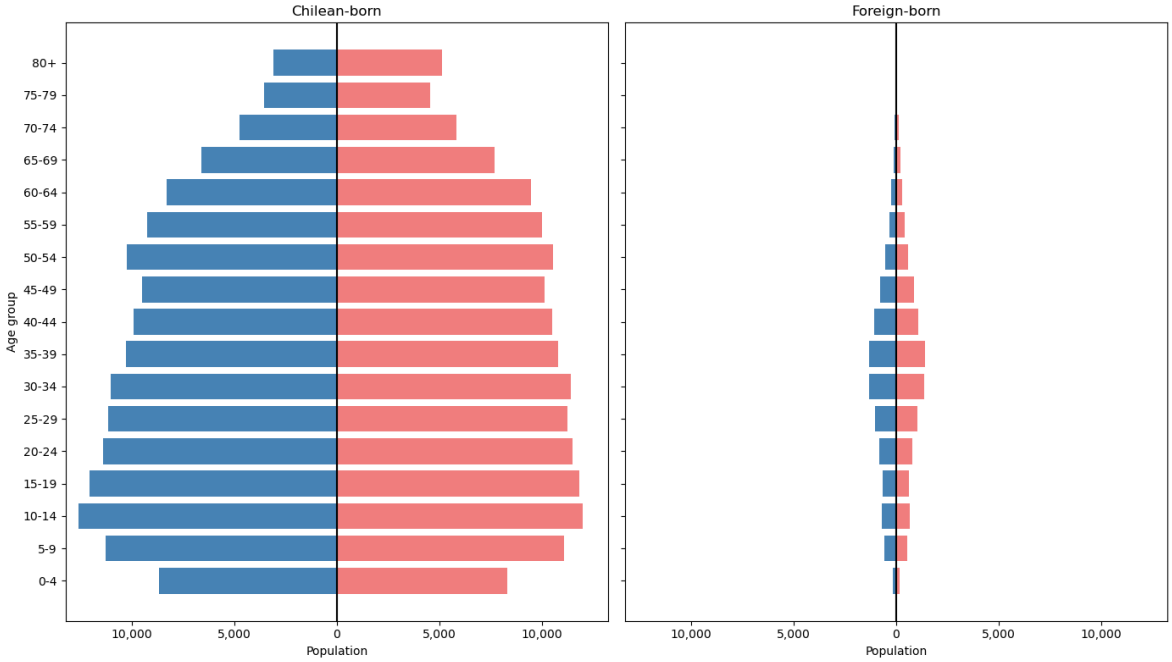

Con las series ya construidas, se graficó la pirámide poblacional separando en dos paneles: uno para la población **chilena** y otro para la **extranjera**. En ambos casos, los hombres se ubicaron al lado izquierdo y las mujeres al lado derecho, manteniendo la misma escala para que la comparación fuera directa y no se distorsionara visualmente.

El resultado muestra una diferencia bien clara entre ambos grupos. La población chilena tiene una estructura mucho más amplia en casi todos los tramos de edad, con mayor peso en edades jóvenes y adultas. En cambio, la población extranjera es bastante menor en tamaño y se concentra principalmente en edades laborales, sobre todo entre los 20 y 40 años. Esto sugiere que la población migrante presente en las comunas analizadas está compuesta en gran parte por personas en etapa activa, mientras que la población chilena refleja una estructura demográfica más completa y diversa en edades.

In [12]:
```
tabla_piramide = pd.DataFrame({
    "Male - Chilean":male_chile.values,
    "Male - Foreign":male_foreign.values,
```

```
    "Female - Chilean":female_chile.values,
    "Female - Foreign":female_foreign.values,}
    ,index=labels)

tabla_piramide
```

Out[12]:

	Male - Chilean	Male - Foreign	Female - Chilean	Female - Foreign
0-4	8683	172	8313	178
5-9	11263	558	11066	554
10-14	12596	680	11986	649
15-19	12060	671	11819	618
20-24	11385	823	11501	805
25-29	11131	1042	11231	1055
30-34	11023	1323	11400	1354
35-39	10264	1332	10778	1396
40-44	9892	1053	10496	1094
45-49	9497	764	10124	870
50-54	10219	530	10532	600
55-59	9250	323	10019	432
60-64	8315	229	9490	283
65-69	6597	106	7697	191
70-74	4756	79	5826	122
75-79	3539	42	4566	63
80+	3106	34	5112	54

- Como complemento para la pirámide, también se armó una tabla con los conteos de población en cada tramo de edad, separados por sexo y por condición de nacionalidad. Así, en vez de ver solo la forma del gráfico, también se pueden revisar los valores exactos detrás de cada barra.

1.2 Dependency Ratio

In [13]:

```
##Sacamos las edades invalidas
dep = df[df["edad"] != -99].copy()

#Grupos por dependencia
dep["grupo_dep"] = pd.cut(dep["edad"],bins=[0, 15, 65, 200],labels=["0-14", "15-

#Conteo de personas por comuna y grupo
tabla_dep = (dep.groupby(["nombre_comuna", "grupo_dep"]).size().unstack(fill_val

#Dependency ratio
```

```
tabla_dep["dependency_ratio"] = ((tabla_dep["0-14"] + tabla_dep["65+"]) / tabla_

dependency_table = tabla_dep
dependency_table
```

```
C:\Users\gusta\AppData\Local\Temp\ipykernel_71176\2346242876.py:8: FutureWarning:
The default of observed=False is deprecated and will be changed to True in a futu
re version of pandas. Pass observed=False to retain current behavior or observed=
True to adopt the future default and silence this warning.
  tabla_dep = (dep.groupby(["nombre_comuna", "grupo_dep"]).size().unstack(fill_va
lue=0).reset_index())
```

Out[13]:

grupo_dep	nombre_comuna	0-14	15-64	65+	dependency_ratio
0	Alhué	1611	5146	1011	0.509522
1	El Monte	7528	24958	5011	0.502404
2	Huechuraba	19459	70891	11458	0.436120
3	La Pintana	35740	117380	22301	0.494471
4	María Pinto	2900	10086	2366	0.522110

Aquí se calculó la **razón de dependencia** para cada comuna, usando la relación entre la población potencialmente dependiente y la población en edad de trabajar. Para eso, primero se excluyeron las edades inválidas (`-99`) y luego se clasificó a las personas en tres grupos: **0–14 años**, **15–64 años** y **65 o más**.

Con esos grupos, se contó cuántas personas había en cada tramo por comuna y luego se aplicó la fórmula de la razón de dependencia: población de **0–14** más población de **65+**, todo dividido por la población de **15–64**. Los resultados muestran valores relativamente parecidos entre comunas, en general cercanos a **0,44–0,52**, lo que indica que por cada persona dependiente hay aproximadamente dos personas en edad activa. Dentro del grupo analizado, **Alhué, María Pinto y Huechuraba** presentan razones algo más altas, mientras que **Huechuraba** muestra la más baja.

1.3 Household size distribution

En este punto se calculó el tamaño de los hogares contando cuántas personas comparten la misma combinación de `id_vivienda` e `id_hogar`. Luego, cada hogar se clasificó según su composición de nacionalidad: **All Chilean** si todos sus integrantes eran chilenos, o **Has Foreign** si al menos una persona del hogar era extranjera. Además, los tamaños más grandes se agruparon en la categoría **8+**.

El gráfico muestra que la mayor parte de los hogares se concentra entre **2 y 4 personas**, tanto en los hogares de solo chilenos como en aquellos con presencia extranjera. También se ve que los hogares “All Chilean” son mucho más numerosos en términos absolutos, lo que era esperable dado su mayor peso dentro de la población total. Aun así, en ambos grupos se repite algo parecido.

In [14]:

```
#Nos quedamos con una fila por persona
base = df.drop_duplicates(subset=["id_vivienda", "id_hogar", "id_persona"]).copy
```

```
#Excluir nacionalidad missing
base = base[base["p27_nacionalidad_rec"] != -99].copy()

#Tamaño del hogar = personas por (id_vivienda, id_hogar)
hh_size = (base.groupby(["id_vivienda", "id_hogar"]).size().rename("hh_size").re

# clasificar hogares por composición de nacionalidad (todos los miembros)
# True si el hogar tiene al menos 1 persona Extranjera
hh_group = (base.groupby(["id_vivienda", "id_hogar"])["p27_nacionalidad_rec"].ap
hh = hh_size.merge(hh_group, on=["id_vivienda", "id_hogar"], how="left")
hh["nat_group"] = hh["has_foreign"].map({False: "All Chilean", True: "Has Foreig

hh["hh_size_bin"] = hh["hh_size"].clip(upper=8)

#Distribución (conteo de hogares)
dist = (hh.groupby(["hh_size_bin", "nat_group"]).size().unstack(fill_value=0).sc

#Gráfico
dist.plot(kind="bar", color={"All Chilean": "steelblue", "Has Foreign": "lightco
plt.xlabel("Household size")
plt.ylabel("Number of households")
plt.title("Household size distribution by nationality group (all members)")
plt.tight_layout()
plt.show()
```

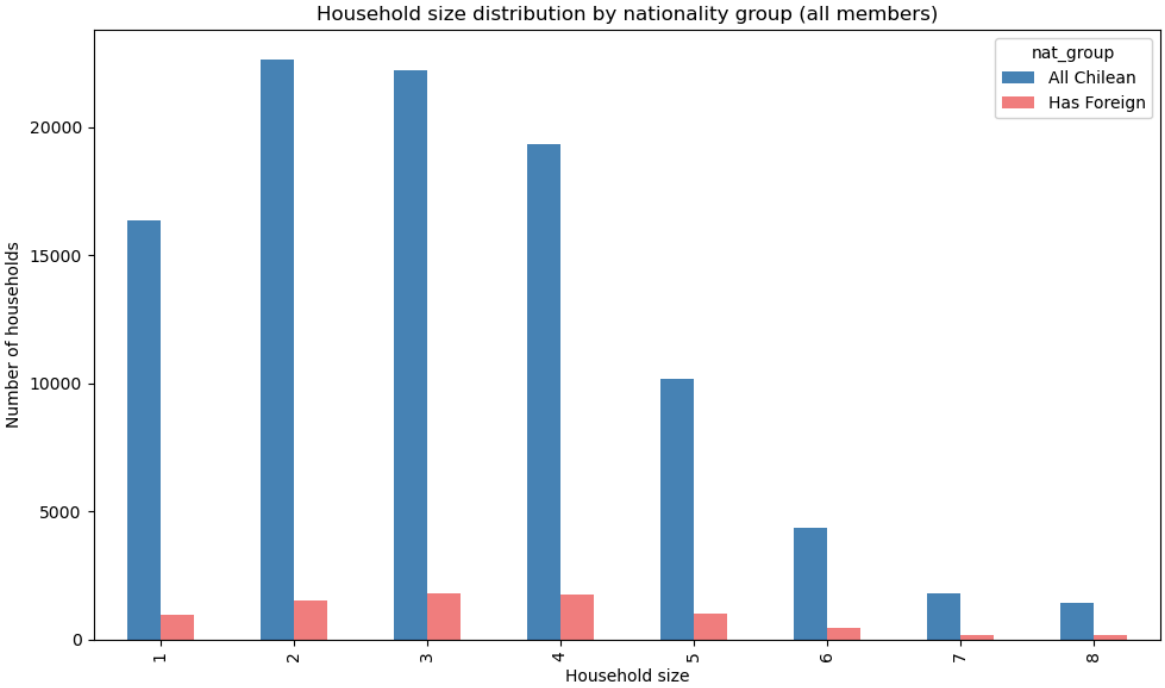

1.4 Education and Employment

In [15]:
```
base = df[
    (df["p27_nacionalidad_rec"] != -99) &
    (df["edad"] != -99)].drop_duplicates(subset=["id_vivienda", "id_hogar", "id_

#Mean years of schooling, edad 25+
educación = base[
    (base["edad"] >= 25) &
    (base["escolaridad"] != -99)].copy()
```

```
educ_summary = (educación.groupby(["nombre_comuna", "p27_nacionalidad_rec"])["es

#Employment rate, edad 15-64
Empleo = base[
    (base["edad"] >= 15) & (base["edad"] <= 64) &
    (base["sit_fuerza_trabajo"] != -99)].copy()

EMPLOYED_CODES = {1}  # si es 1 significa ocupado
Empleo["is_employed"] = Empleo["sit_fuerza_trabajo"].isin(EMPLOYED_CODES).astype

emp_summary = (Empleo.groupby(["nombre_comuna", "p27_nacionalidad_rec"])["is_emp

summary = educ_summary.merge(emp_summary,on=["nombre_comuna", "p27_nacionalidad_

summary["nat_group"] = summary["p27_nacionalidad_rec"].map({1: "Chilean", 2: "Fo

edu_piv = summary.pivot(index="nombre_comuna", columns="nat_group", values="mean
emp_piv = summary.pivot(index="nombre_comuna", columns="nat_group", values="empl

#Gráfico 1: escolaridad
edu_piv.plot(kind="bar", color=["darkred", "darkorange"])
plt.ylabel("Mean years of schooling (25+)")
plt.xlabel("Comuna")
plt.title("Mean schooling by comuna and nationality (25+)")
plt.tight_layout()
plt.show()

#Gráfico 2: empleo en %
(emp_piv * 100).plot(kind="bar", color=["dodgerblue", "greenyellow"])
plt.ylabel("Employment rate (%) (15–64)")
plt.xlabel("Comuna")
plt.title("Employment rate by comuna and nationality (15–64)")
plt.ylim(0, 100)
plt.tight_layout()
plt.show()
```

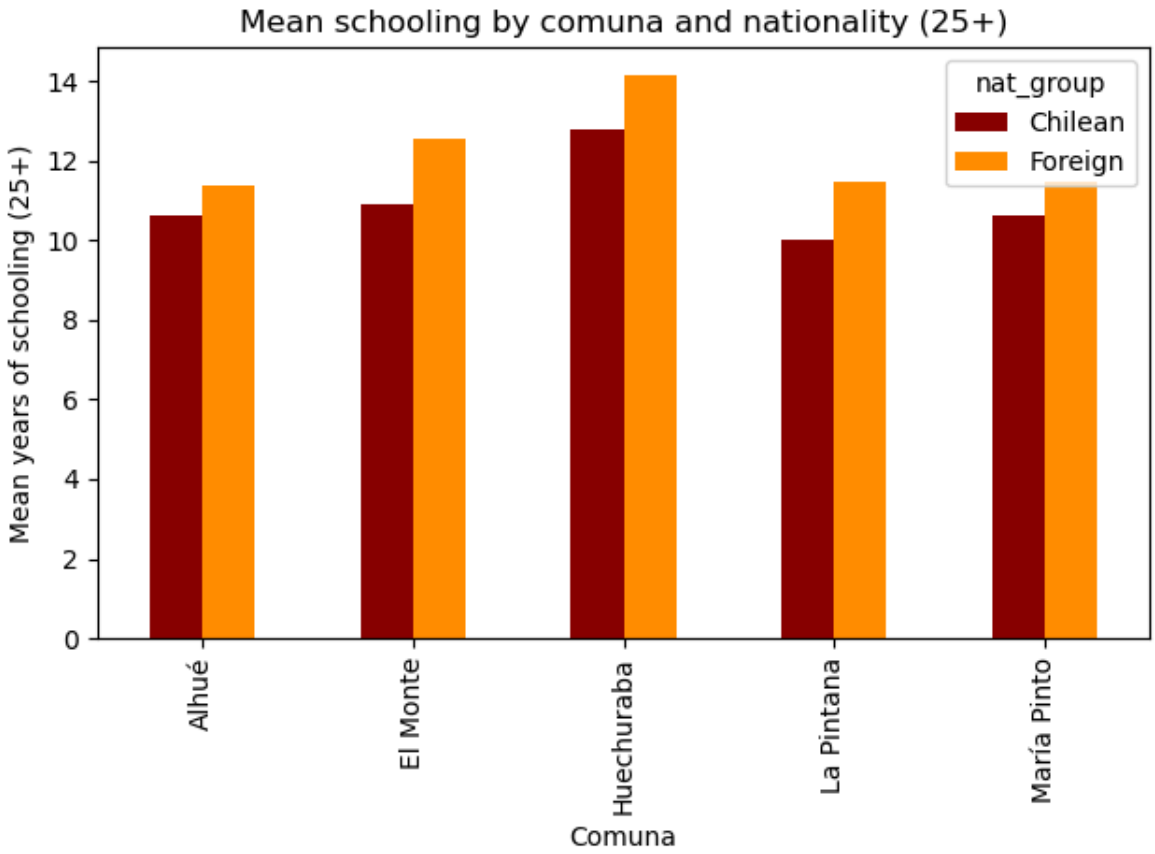

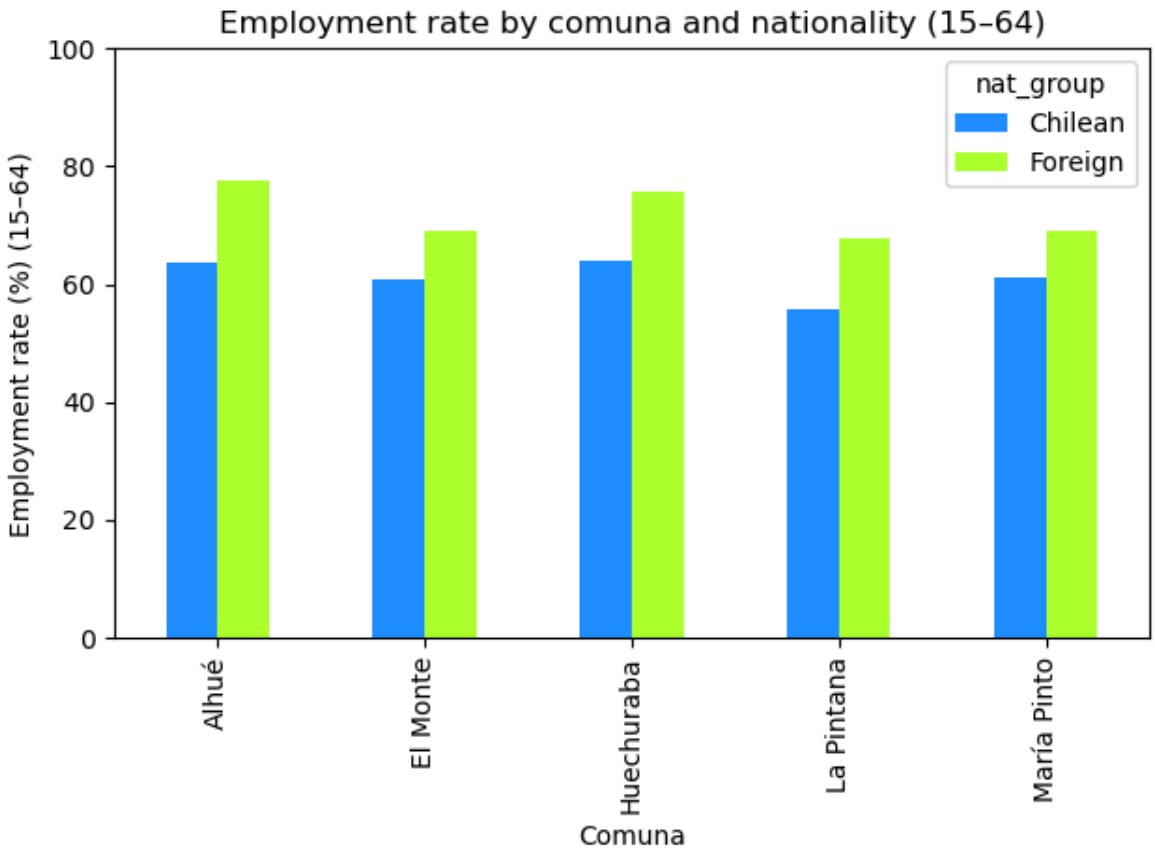

En este punto se compararon dos indicadores entre comunas y por grupo de nacionalidad: los **años promedio de escolaridad** para la población de **25 años o más**, y la **tasa de empleo** para la población entre **15 y 64 años**. Para ambos casos se trabajó solo con registros válidos, excluyendo edades, escolaridad o situación laboral marcadas como faltante.

Los gráficos muestran un patrón bastante consistente: en las 5 comunas analizadas, la población **extranjera** presenta en promedio **más años de escolaridad** que la población chilena, y además registra una **tasa de empleo mayor**. También se observan diferencias entre comunas. Por ejemplo, **Huechuraba** destaca con los niveles más altos tanto en escolaridad como en empleo, mientras que **La Pintana** aparece más abajo en ambos. Sugiriendo que la población extranjera presente en estas comunas no solo está más concentrada en edades activas(Fuerza de trabajo), sino que además muestra una inserción laboral ligeramente más fuerte y un nivel educativo en promedio un poco más alto que el de la población chilena.

- Como apoyo a los gráficos, también se generaron dos tablas resumen. La primera muestra los **años promedio de escolaridad** para la población, separados por comuna y por grupo de nacionalidad. La segunda presenta la **tasa de empleo** para la población, calculada como la proporción de personas ocupadas de cada grupo(Chilenos o extranjeros).

In [16]:
```
edu = df[
    (df["edad"] != -99) &
    (df["edad"] >= 25) &
    (df["escolaridad"] != -99) &
    (df["p27_nacionalidad_rec"] != -99)].drop_duplicates(subset=["id_vivienda",

edu["nat_group"] = edu["p27_nacionalidad_rec"].map({1: "Chilean", 2: "Foreign"})

edu_summary = (edu.groupby(["nombre_comuna", "nat_group"])["escolaridad"].mean()

edu_summary
```

Out[16]:

	nombre_comuna	nat_group	mean_schooling
0	Alhué	Chilean	10.596439
1	Alhué	Foreign	11.376325
2	El Monte	Chilean	10.904782
3	El Monte	Foreign	12.531343
4	Huechuraba	Chilean	12.773288
5	Huechuraba	Foreign	14.123670
6	La Pintana	Chilean	10.012210
7	La Pintana	Foreign	11.472633
8	María Pinto	Chilean	10.600078
9	María Pinto	Foreign	11.465000

In [17]:
```
work = df[
    (df["edad"] != -99) &
    (df["edad"] >= 15) & (df["edad"] <= 64) &
    (df["sit_fuerza_trabajo"] != -99) &
    (df["p27_nacionalidad_rec"] != -99)].drop_duplicates(subset=["id_vivienda",
```

```
work["nat_group"] = work["p27_nacionalidad_rec"].map({1: "Chilean", 2: "Foreign"
work["is_employed"] = (work["sit_fuerza_trabajo"] == 1).astype(int)

emp_summary = (work.groupby(["nombre_comuna", "nat_group"])["is_employed"].mean(

emp_summary
```

Out[17]:

	nombre_comuna	nat_group	employment_rate
0	Alhué	Chilean	0.637849
1	Alhué	Foreign	0.775172
2	El Monte	Chilean	0.607493
3	El Monte	Foreign	0.691375
4	Huechuraba	Chilean	0.639157
5	Huechuraba	Foreign	0.758027
6	La Pintana	Chilean	0.557072
7	La Pintana	Foreign	0.676801
8	María Pinto	Chilean	0.610828
9	María Pinto	Foreign	0.692000

2.1 Percentege foreign-born by comuna

En este punto se calculó el porcentaje de población extranjera en cada comuna, considerando solo registros válidos y evitando duplicar personas en caso de que el `join` hubiera repetido observaciones. Para eso, primero se creó una variable indicadora que toma valor 1 cuando la persona es extranjera y 0 en caso contrario, y luego se obtuvo el promedio de esa variable por comuna. Al multiplicar ese promedio por 100, se obtiene directamente el porcentaje de residentes extranjeros.

Tanto la tabla como el gráfico muestran diferencias claras entre comunas. **Alhué** aparece con el porcentaje más alto de población extranjera, con un valor cercano a **11,3%**, seguida por **Huechuraba** con un **8%**. Más abajo quedan **La Pintana**, **El Monte** y **María Pinto**, con proporciones bastante menores. Sugiriendo que la población extranjera se concentra más en algunas comunas mas que en otras.

In [18]:

```
base = df[df["p27_nacionalidad_rec"] != -99].drop_duplicates(subset=["id_viviend

foreign_table = (base.assign(is_foreign=(base["p27_nacionalidad_rec"] == 2).asty
        .groupby("nombre_comuna")["is_foreign"].mean().mul(100)
        .reset_index(name="%_foreign").sort_values("%_foreign", ascending=False)

foreign_table["%_foreign"] = foreign_table["%_foreign"].round(2)
foreign_table
```

Out[18]:

	nombre_comuna	%_foreign
0	Alhué	11.34
2	Huechuraba	8.28
3	La Pintana	4.44
1	El Monte	2.45
4	María Pinto	2.08

In [19]:
```
foreign_table.set_index("nombre_comuna")["%_foreign"].plot(kind="bar", color="me
plt.ylabel("Foreign-born (%)")
plt.xlabel("Comuna")
plt.title("Percentage of foreign-born residents by comuna")
plt.tight_layout()
plt.show()
```

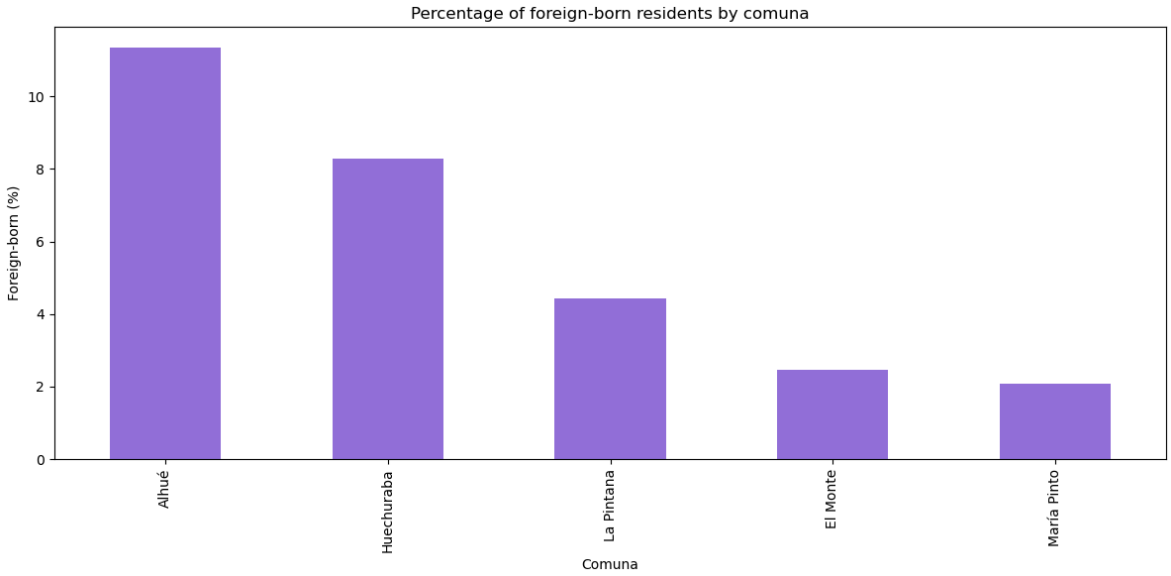

2.2 Top Nacionalities

En este punto se identificaron las nacionalidades más frecuentes dentro de la población extranjera de las comunas analizadas. Para eso, primero se filtraron solo las personas extranjeras y se excluyeron los casos sin respuesta o con valor anonimizado. Luego, usando el diccionario de códigos territoriales específicos, se transformaron los códigos de nacionalidad en nombres de países o territorios para que el resultado fuera más interpretable.

La tabla y el gráfico muestran una concentración bastante marcada en unas pocas nacionalidades. **Venezuela** aparece con mucha diferencia como la nacionalidad más frecuente, seguida por **Perú**, **Colombia** y **Haití**. Más abajo aparecen Bolivia, Argentina y otros grupos más agregados, como “otros países de América del Sur”. Indicando que la población extranjera presente en las comunas proviene principalmente de países latinoamericanos, Pero con mayor presencia de la migración venezolana.

In [20]:
```
base = df[
    (df["p27_nacionalidad_rec"] == 2) &
```

```
    (df["p27_nacionalidad_esp"] != -99) &
    (df["p27_nacionalidad_esp"] != -66)
].drop_duplicates(subset=["id_vivienda", "id_hogar", "id_persona"]).copy()

top10_codes = base["p27_nacionalidad_esp"].value_counts().head(10)
top10_codes
```

Out[20]:

```
p27_nacionalidad_esp
862    6597
604    3909
170    2177
332    1764
5      1153
68      941
32      720
13      475
150     231
142     186
Name: count, dtype: int64
```

In [21]:

```
xls = pd.ExcelFile("diccionario_variables_censo2024.xlsx")
print(xls.sheet_names)

dic_paises = pd.read_excel("diccionario_variables_censo2024.xlsx", sheet_name="c
dic_paises

dic_paises.columns
```

```
['tabla_viviendas', 'tabla_hogares', 'tabla_personas', 'cod_territoriales_especif
icos', 'codigos_territoriales']
```

Out[21]:

```
Index(['Código específico', 'Territorio específico'], dtype='object')
```

In [22]:

```
#Filtrar solo extranjeros, excluyendo los que no responden o respuestas anonimas
base = df[
    (df["p27_nacionalidad_rec"] == 2) &
    (df["p27_nacionalidad_esp"] != -99) &
    (df["p27_nacionalidad_esp"] != -66)].drop_duplicates(subset=["id_vivienda",

#Top 10(Nacionalidades)
top10_codes = base["p27_nacionalidad_esp"].value_counts().head(10)

#Carga del diccionario para los códigos y nombres de países
dic_paises = pd.read_excel("diccionario_variables_censo2024.xlsx",sheet_name="co

# De código a país
mapping = dict(zip(dic_paises["Código específico"], dic_paises["Territorio espec

top10_named = top10_codes.rename_axis("codigo").reset_index(name="count")
top10_named["pais"] = top10_named["codigo"].map(mapping)
top10_named = top10_named.sort_values("count")

print(top10_named)

#Grafica
plt.figure(figsize=(10, 6))
plt.barh(top10_named["pais"], top10_named["count"], color="seagreen")
plt.xlabel("Number of foreign-born residents")
plt.ylabel("Nationality")
plt.title("Top 10 nationalities among foreign-born residents")
```

```
plt.tight_layout()
plt.show()
```

```
   codigo  count                                      pais
9     142    186                                      Asia
8     150    231                                    Europa
7      13    475  Otros países de América Central y El Caribe
6      32    720                                 Argentina
5      68    941            Bolivia (Estado Plurinacional de)
4       5   1153              Otros países de América del Sur
3     332   1764                                     Haití
2     170   2177                                  Colombia
1     604   3909                                      Perú
0     862   6597          Venezuela (República Bolivariana de)
```

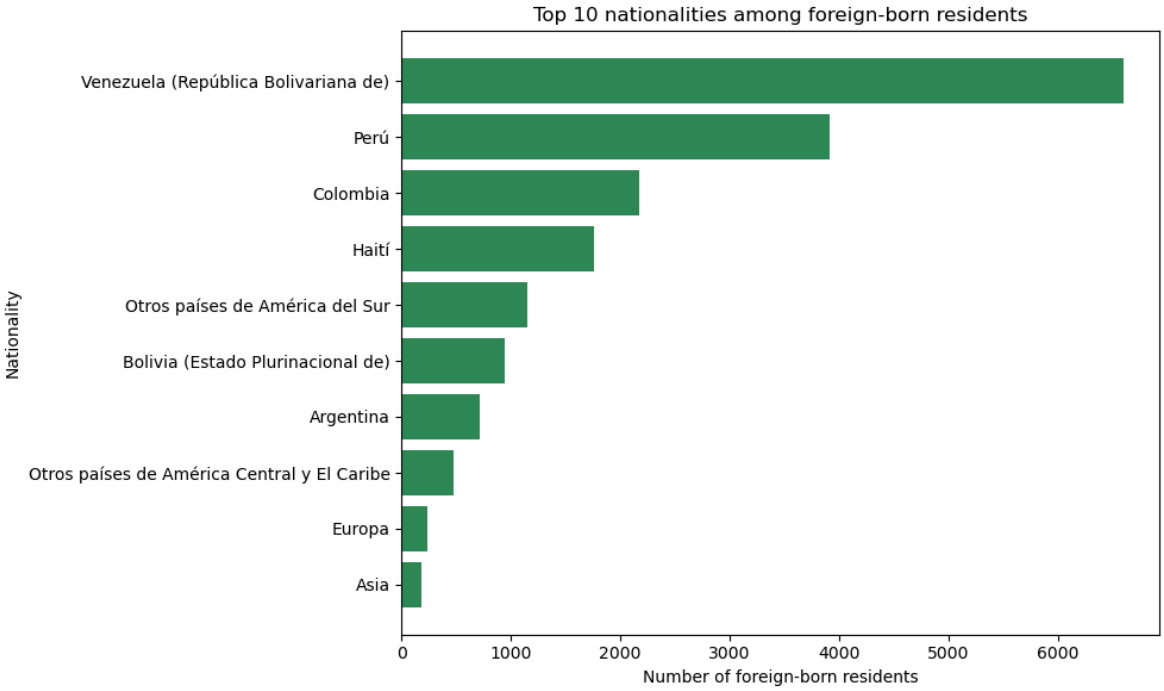

2.3 Migration Status: Residence 5 years ago

En este punto se analizó dónde vivían las personas hace cinco años, usando la variable `p24_lug_resid5` y excluyendo tanto las edades inválidas como los menores de 5 años, ya que para ellos la pregunta no aplica. A partir de esa información se construyeron cuatro categorías: quienes vivían en la **misma comuna**, en una **comuna distinta de la misma región**, en una **región distinta** y en el **extranjero**. Luego se calculó el peso porcentual de cada grupo dentro de cada comuna.

In [23]:
```
#Base
base = df[
    (df["edad"] != -99) &
    (df["edad"] >= 5) &
    (df["p24_lug_resid5"] != -99)].drop_duplicates(subset=["id_vivienda", "id_ho
base["comuna_str"] = base["comuna"].astype(str).str.zfill(5)
base["resid5_esp_str"] = base["p24_lug_resid5_esp"].astype(str).str.zfill(5)

#Región actual y hace 5 años
base["region_actual"] = base["comuna_str"].str[:2]
base["region_resid5"] = base["resid5_esp_str"].str[:2]
```

```
#Grupo migratorio
base["mig_group"] = None
base.loc[base["p24_lug_resid5"] == 2, "mig_group"] = "Same comuna"
base.loc[base["p24_lug_resid5"] == 4, "mig_group"] = "Abroad"
base.loc[(base["p24_lug_resid5"] == 3) &(base["region_actual"] == base["region_r
base.loc[(base["p24_lug_resid5"] == 3) &(base["region_actual"] != base["region_r

# tabla porcentual por comuna
mig_table = (
    base.groupby(["nombre_comuna", "mig_group"]).size().groupby(level=0, group_k

mig_piv = (mig_table.pivot(index="nombre_comuna", columns="mig_group", values="p

#Orden de columnas
mig_piv = mig_piv[["Same comuna", "Different comuna, same region", "Different re

#Gráfico
mig_piv.plot(kind="bar", stacked=True, figsize=(12, 6))
plt.ylabel("Percentage of population")
plt.xlabel("Comuna")
plt.title("Place of residence 5 years ago by comuna")
plt.legend(title="Residence 5 years ago", bbox_to_anchor=(1.05, 1), loc="upper l
plt.tight_layout()
plt.show()
```

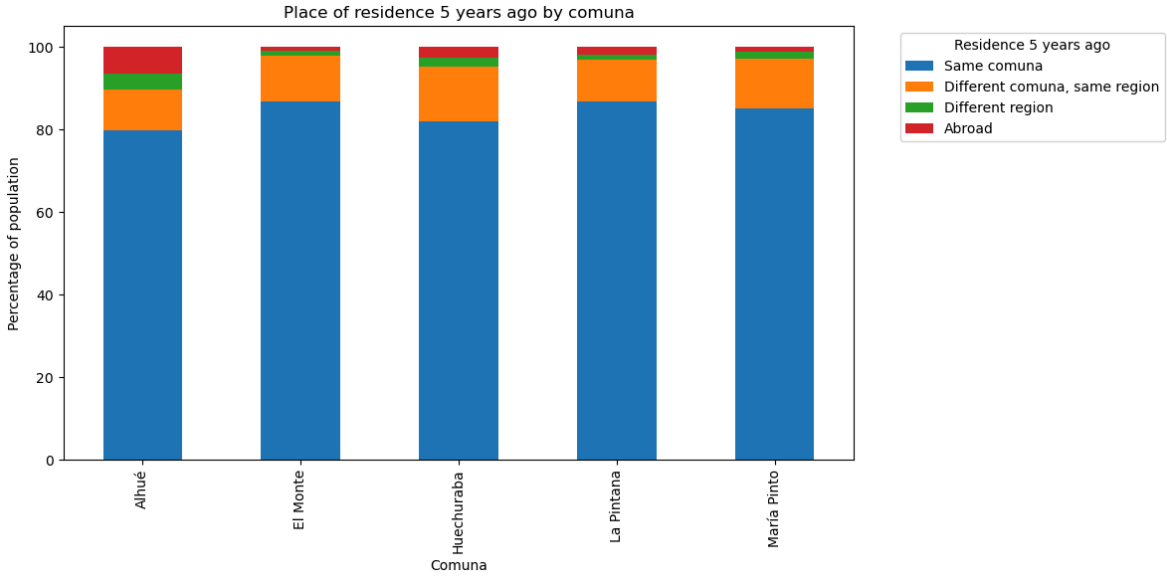

- El gráfico muestra un patrón bastante claro: en las cinco comunas, la gran mayoría de la población ya vivía en la **misma comuna** cinco años antes del censo. El segundo grupo más importante corresponde a personas que vivían en **otra comuna de la misma región**, mientras que los casos de residencia en **otra región** o en el **extranjero** son menores. Entre las comunas, **Alhué** parece tener una proporción algo más baja de residentes estables y una fracción relativamente mayor de personas que vivían fuera de la comuna o incluso fuera del país, mientras que comunas como **El Monte** y **La Pintana** muestran mas permanencia o población que se no se cambia demasiado de comuna.

2.4 Arrival Period of Inmigrants

Acá utilizamos la variable `p26_llegada_periodo` para analizar en que periodo llegaron los inmigrantes. Para eso, primero se eliminó cualquier posible duplicado de personas y se filtraron los casos con información válida, excluyendo faltantes o no respondidos. Después, se codificaron a intervalos de tiempo más fáciles de interpretar, desde **2023–2024** hasta **antes de 1990**, de la misma forma que el diccionario de las variables.

La tabla muestra que la mayor parte de las llegadas se concentra en los períodos más recientes, especialmente entre **2017 y 2019**, seguido por **2020–2022** y **2014–2016**. También hay una presencia importante de llegadas entre **2023 y 2024**, lo que sugiere que la inmigración en estas comunas sigue siendo un fenómeno bastante actual. En cambio, los grupos correspondientes a llegadas más antiguas, como **1990–1999** o **antes de 1990**, son bastante menores.

In [24]:
```
base = df.drop_duplicates(subset=["id_vivienda", "id_hogar", "id_persona"]).copy

## Excluimos personas sin info de llegada
base = base[base["p26_llegada_periodo"].notna() & (base["p26_llegada_periodo"] !

mapping_arrival = {
    1: "2023-2024",
    2: "2020-2022",
    3: "2017-2019",
    4: "2014-2016",
    5: "2010-2013",
    6: "2000-2009",
    7: "1990-1999",
    8: "Before 1990"}

arrival_table = (base["p26_llegada_periodo"].value_counts().sort_index().rename_

arrival_table["periodo"] = arrival_table["codigo"].map(mapping_arrival)

arrival_table
```

Out[24]:

	codigo	count	periodo
0	1.0	2173	2023-2024
1	2.0	4261	2020-2022
2	3.0	5467	2017-2019
3	4.0	3075	2014-2016
4	5.0	1728	2010-2013
5	6.0	2072	2000-2009
6	7.0	799	1990-1999
7	8.0	433	Before 1990

In [25]:
```
plt.figure(figsize=(12, 6))
plt.bar(arrival_table["periodo"], arrival_table["count"], color="darkred")
plt.xlabel("Arrival period")
plt.ylabel("Number of immigrants")
plt.title("Arrival period of immigrants")
```

```
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```

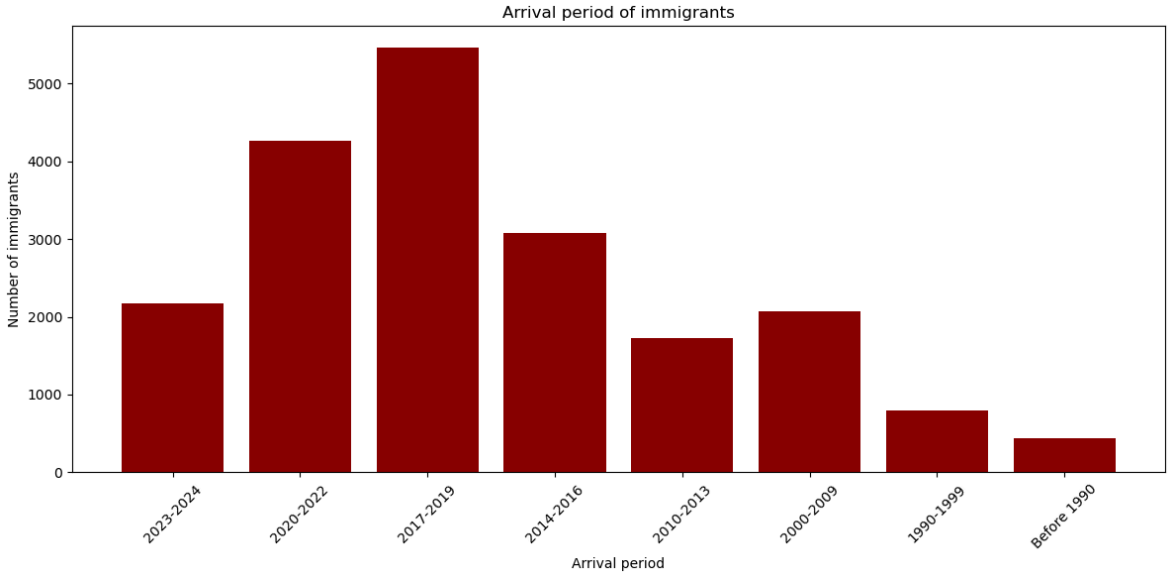

3.1 Choropleth map: population by comuna

Para este mapa se utilizó el shapefile de comunas y se hizo un `merge` con la población total calculada previamente a partir de la base consolidada. En vez de mostrar solo las comunas asignadas aisladas, se dejó el mapa completo como fondo en color neutro y luego se destacaron únicamente las comunas de interés con una escala de color según su población. Además, se ajustó el zoom a la zona relevante y se agregaron etiquetas con el nombre de cada comuna para facilitar la lectura.

El resultado permite comparar de manera visual el tamaño poblacional de las comunas asignadas. **La Pintana** destaca claramente como la comuna con mayor población dentro del grupo, seguida por **Huechuraba**. En cambio, **Alhué**, **María Pinto** y **El Monte** aparecen con valores bastante menores, lo que se refleja en tonos más claros. En conjunto, el mapa muestra que las comunas analizadas son bastante distintas entre sí en términos de tamaño poblacional.

In [26]:
```
comunas_gdf = gpd.read_file("Comunas/comunas.shp")

comunas_gdf.columns
```

Out[26]:
```
Index(['objectid', 'shape_leng', 'dis_elec', 'cir_sena', 'cod_comuna',
       'codregion', 'st_area_sh', 'st_length_', 'Region', 'Comuna',
       'Provincia', 'geometry'],
      dtype='object')
```

In [27]:
```
#Población total por comuna
pob_comuna = (df.drop_duplicates(subset=["id_vivienda", "id_hogar", "id_persona"

#Shapefile
comunas_gdf = gpd.read_file("Comunas/comunas.shp")
comunas_gdf["comuna"] = comunas_gdf["cod_comuna"].astype(int)

#Merge
```

```
map_gdf = comunas_gdf.merge(pob_comuna, on="comuna", how="left")

#Meter nuestras comunas
map_sel = map_gdf[map_gdf["comuna"].isin(OUR_COMUNAS)].copy()
fig, ax = plt.subplots(figsize=(10, 10))

#Todas las demas comunas en gris
map_gdf.plot(ax=ax,color="white",edgecolor="lightgray",linewidth=0.5)

#Comunas nuestras en verde
map_sel.plot(column="population",cmap="Greens",legend=True,edgecolor="black",lin

#Zoom
xmin, ymin, xmax, ymax = map_sel.total_bounds
xpad = (xmax - xmin) * 0.3
ypad = (ymax - ymin) * 0.3
ax.set_xlim(xmin - xpad, xmax + xpad)
ax.set_ylim(ymin - ypad, ymax + ypad)

#Etiquetas
map_sel["centroid"] = map_sel.geometry.centroid
for _, row in map_sel.iterrows():
    ax.text(
        row["centroid"].x,
        row["centroid"].y,
        row["Comuna"],   # nombre desde el shapefile
        fontsize=8,
        ha="center",
        va="center",
        bbox=dict(facecolor="white", alpha=0.7, edgecolor="none"))

ax.set_title("Total population by comuna")
ax.axis("off")
plt.tight_layout()
plt.show()
```

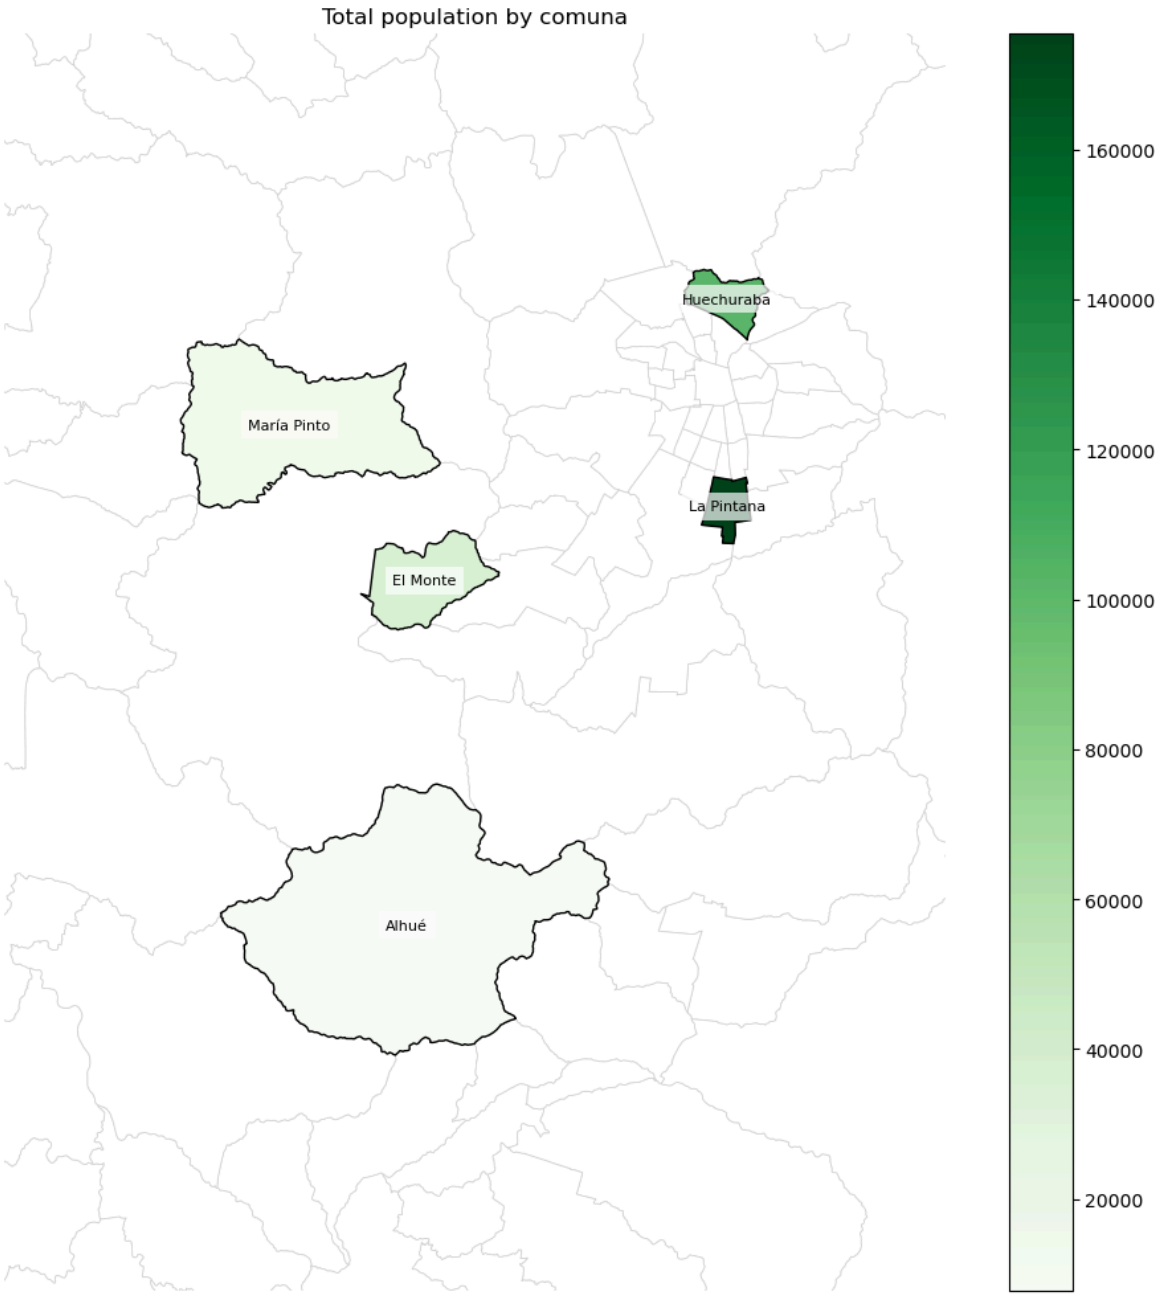

3.2 Choropleth map: % foreign-born by comuna

Para este segundo mapa se siguió una lógica similar al anterior, pero en vez de representar población total se usó el **porcentaje de población extranjera** en cada comuna. Primero se calculó ese porcentaje a partir de la base consolidada, y luego se hizo el `merge` con el shapefile de comunas para poder llevar esa información al espacio geográfico. Igual que en el mapa previo, se dejó el resto de las comunas como fondo neutro, se hizo zoom sobre el área relevante y se añadieron etiquetas para que la lectura fuera más clara.

El mapa muestra con bastante claridad que la presencia de población extranjera no se distribuye de manera homogénea entre las comunas analizadas. **Alhué** destaca con el porcentaje más alto, seguida por **Huechuraba**, mientras que **La Pintana**, **El Monte** y sobre todo **María Pinto** presentan valores menores. Esto refuerza lo que ya se veía en la

tabla y en el gráfico de barras: aunque la población extranjera existe en todas las comunas estudiadas, su peso relativo cambia bastante entre comunas

In [28]:
```
# % foreign-born por comuna
foreign_comuna = (df[df["p27_nacionalidad_rec"] != -99]
      .drop_duplicates(subset=["id_vivienda", "id_hogar", "id_persona"])
      .assign(pct_foreign=(df.loc[df["p27_nacionalidad_rec"] != -99, "p27_nacion
      .groupby(["comuna", "nombre_comuna"])["pct_foreign"]
      .mean()
      .mul(100)
      .reset_index(name="pct_foreign"))

#Shapefile
comunas_gdf = gpd.read_file("Comunas/comunas.shp")
comunas_gdf["comuna"] = comunas_gdf["cod_comuna"].astype(int)

#Merge de nuevo
map_gdf = comunas_gdf.merge(foreign_comuna, on="comuna", how="left")

#Nuestras comunas
map_sel = map_gdf[map_gdf["comuna"].isin(OUR_COMUNAS)].copy()

fig, ax = plt.subplots(figsize=(10, 10))

#Las demas comunas en gris
map_gdf.plot(ax=ax,color="white",edgecolor="lightgray",linewidth=0.5)

#Nuestras comunas coloreadas
map_sel.plot(column="pct_foreign",cmap="YlOrRd",legend=True,edgecolor="black",li

#Zoom
xmin, ymin, xmax, ymax = map_sel.total_bounds
xpad = (xmax - xmin) * 0.3
ypad = (ymax - ymin) * 0.3
ax.set_xlim(xmin - xpad, xmax + xpad)
ax.set_ylim(ymin - ypad, ymax + ypad)

#Etiquetas
map_sel["centroid"] = map_sel.geometry.centroid
for _, row in map_sel.iterrows():
    ax.text(
        row["centroid"].x,
        row["centroid"].y,
        row["Comuna"],
        fontsize=8,
        ha="center",
        va="center",
        bbox=dict(facecolor="white", alpha=0.7, edgecolor="none"))

ax.set_title("% foreign-born by comuna")
ax.axis("off")
plt.tight_layout()
plt.show()
```

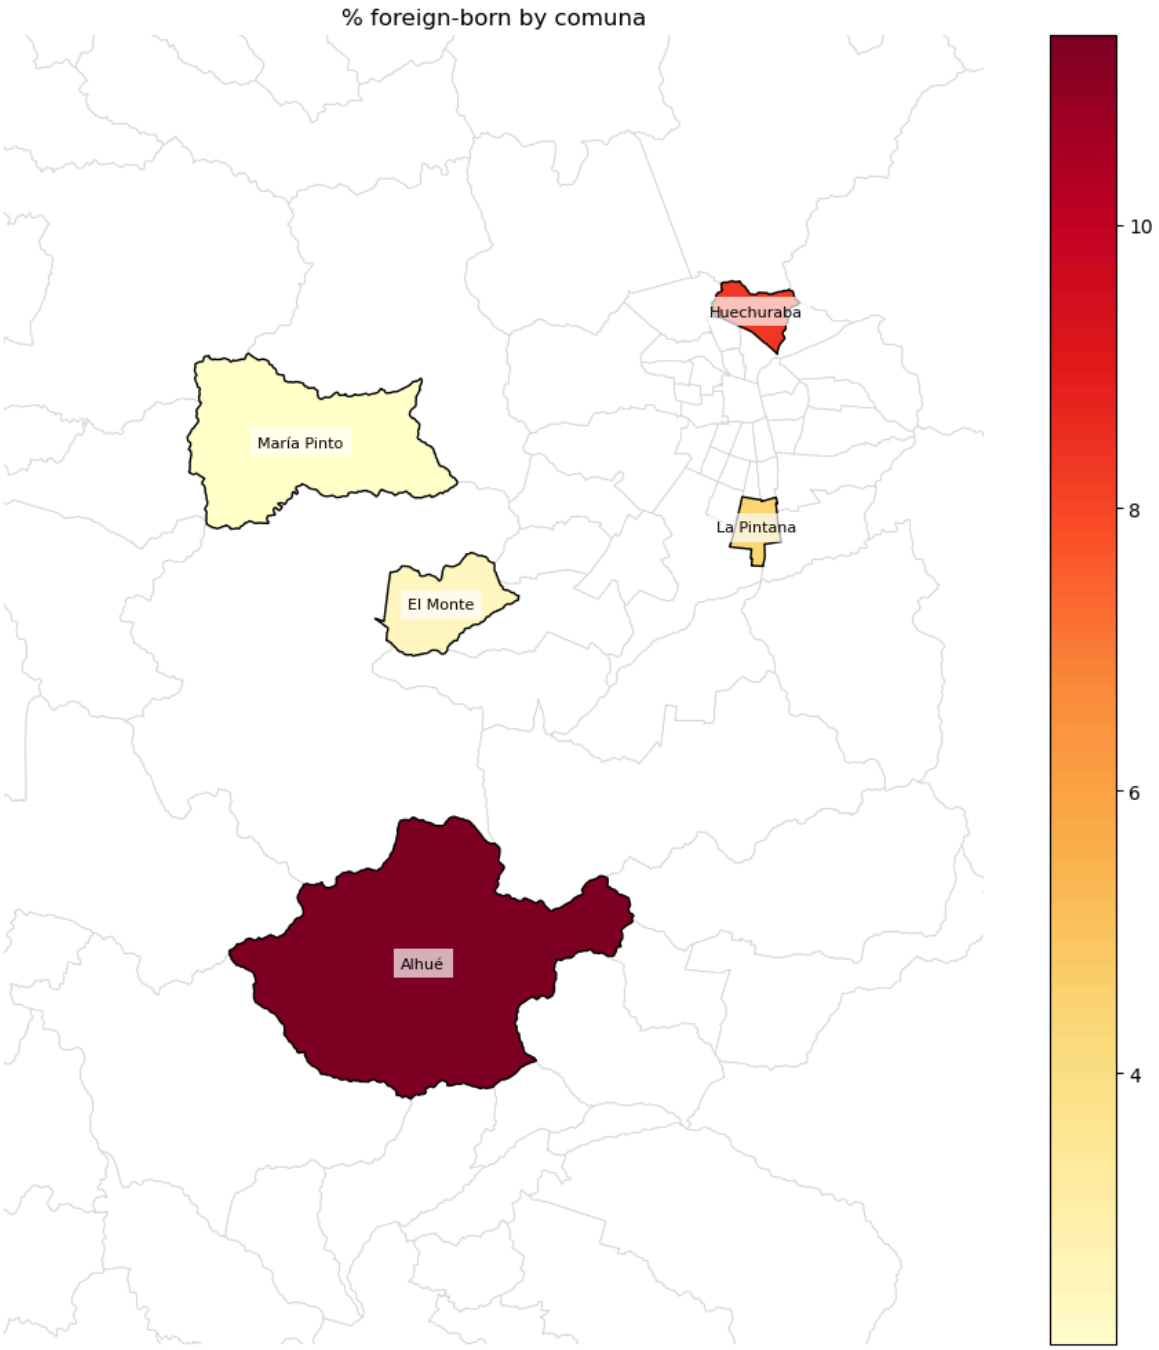

Part 4: Comuna-Level Summary Table (1 pt)

En esta última parte se construyó una **tabla resumen a nivel de comuna**, dejando una sola fila por cada una de las comunas analizadas. Para eso, primero se eliminó cualquier posible duplicación de personas y luego se definió una función (`build_summary`) que calcula, para cada comuna, un conjunto de indicadores demográficos y socioeconómicos.

La función reúne en una sola salida varias medidas que ya se habían trabajado por separado a lo largo de la tarea: población total, población chilena y extranjera, porcentaje de extranjeros, edad mediana por grupo, escolaridad promedio en mayores de 25 años, tasa de empleo entre 15 y 64 años y razón de dependencia. En todos los casos se excluyeron los valores faltantes (`-99`) para no contaminar los resultados.

Después, esa función se aplicó automáticamente a cada comuna usando `groupby("comuna")`, lo que permitió generar una tabla final compacta y comparable entre territorios. Por último, se redondearon las columnas principales para dejar el resultado más ordenado y fácil de leer. Esta tabla resume en un solo lugar los indicadores más importantes del análisis y funciona como síntesis general de la tarea.

In [29]:
```
#Base
base = df.drop_duplicates(subset=["id_vivienda", "id_hogar", "id_persona"]).copy

def build_summary(g):
    out = {}

    out["codigo_comuna"] = g["comuna"].iloc[0]
    out["nombre_comuna"] = g["nombre_comuna"].iloc[0]

    #Población total
    out["pop_total"] = len(g)

    #Población chilena / extranjera
    g_nat = g[g["p27_nacionalidad_rec"] != -99].copy()
    out["pop_chilean"] = (g_nat["p27_nacionalidad_rec"] == 1).sum()
    out["pop_foreign"] = (g_nat["p27_nacionalidad_rec"] == 2).sum()

    if len(g_nat) > 0:
        out["pct_foreign"] = (out["pop_foreign"] / len(g_nat)) * 100
    else:
        out["pct_foreign"] = None

    #Edad mediana
    g_age = g[g["edad"] != -99].copy()

    age_chilean = g_age[g_age["p27_nacionalidad_rec"] == 1]["edad"]
    age_foreign = g_age[g_age["p27_nacionalidad_rec"] == 2]["edad"]

    out["median_age_chilean"] = age_chilean.median() if len(age_chilean) > 0 els
    out["median_age_foreign"] = age_foreign.median() if len(age_foreign) > 0 els

    #Escolaridad promedio
    g_edu = g[(g["edad"] != -99) &(g["edad"] >= 25) &(g["escolaridad"] != -99)].

    edu_chilean = g_edu[g_edu["p27_nacionalidad_rec"] == 1]["escolaridad"]
    edu_foreign = g_edu[g_edu["p27_nacionalidad_rec"] == 2]["escolaridad"]

    out["mean_schooling_chilean"] = edu_chilean.mean() if len(edu_chilean) > 0 e
    out["mean_schooling_foreign"] = edu_foreign.mean() if len(edu_foreign) > 0 e

    #Tasa de empleo (15-64)
    g_work = g[
        (g["edad"] != -99) &
        (g["edad"] >= 15) & (g["edad"] <= 64) &
        (g["sit_fuerza_trabajo"] != -99)].copy()

    work_chilean = g_work[g_work["p27_nacionalidad_rec"] == 1]
    work_foreign = g_work[g_work["p27_nacionalidad_rec"] == 2]

    out["emp_rate_chilean"] = (
        (work_chilean["sit_fuerza_trabajo"] == 1).mean() * 100
        if len(work_chilean) > 0 else None)
```

```
    out["emp_rate_foreign"] = (
        (work_foreign["sit_fuerza_trabajo"] == 1).mean() * 100
        if len(work_foreign) > 0 else None)

    #Dependency ratio (overall)
    dep = g[g["edad"] != -99]["edad"]

    pop_0_14 = ((dep >= 0) & (dep <= 14)).sum()
    pop_15_64 = ((dep >= 15) & (dep <= 64)).sum()
    pop_65_plus = (dep >= 65).sum()

    out["dependency_ratio"] = (((pop_0_14 + pop_65_plus) / pop_15_64)
        if pop_15_64 > 0 else None)
    return pd.Series(out)

summary = base.groupby("comuna").apply(build_summary).reset_index(drop=True)

#Redondear algunas columnas
cols_round = [
    "pct_foreign",
    "median_age_chilean",
    "median_age_foreign",
    "mean_schooling_chilean",
    "mean_schooling_foreign",
    "emp_rate_chilean",
    "emp_rate_foreign",
    "dependency_ratio"]

summary[cols_round] = summary[cols_round].round(2)

summary
```

```
C:\Users\gusta\AppData\Local\Temp\ipykernel_71176\2718845283.py:69: DeprecationWa
rning: DataFrameGroupBy.apply operated on the grouping columns. This behavior is
deprecated, and in a future version of pandas the grouping columns will be exclud
ed from the operation. Either pass `include_groups=False` to exclude the grouping
s or explicitly select the grouping columns after groupby to silence this warnin
g.
  summary = base.groupby("comuna").apply(build_summary).reset_index(drop=True)
```

Out[29]:

	codigo_comuna	nombre_comuna	pop_total	pop_chilean	pop_foreign	pct_foreign
0	13107	Huechuraba	101808	92790	8381	8.28
1	13112	La Pintana	175421	166483	7732	4.44
2	13502	Alhué	7768	6871	879	11.34
3	13504	María Pinto	15352	14996	319	2.08
4	13602	El Monte	37497	36404	915	2.45

In [30]:

```
summary.to_csv("output_tarea1_comuna_summary.csv", index=False)
```

Finalmente este resumen hecho en el punto anterior es traspasado a un archivo csv